


Arbre de décision

1) un arbre pour décider si on achète

A) Choisir un attribut pour la racine en sélectionnant le gain d'informations (IG) le plus grand




$$IG(\text{Sexe}) = 1 - \left[\frac{3}{11} I(3/7, 4/7) + \frac{7}{11} I(4/7, 3/7) \right] = 1 - \left[\frac{3}{11} (0,985228) + \frac{7}{11} (0,985228) \right] = 0,014772$$

$$I(3/7, 4/7) = -\frac{3}{7} \log \frac{3}{7} - \frac{4}{7} \log \frac{4}{7} \approx 0,985228$$

$$I(4/7, 3/7) = -\frac{4}{7} \log \frac{4}{7} - \frac{3}{7} \log \frac{3}{7} \approx 0,985228$$

$$IG(\text{Sexe}) = 0,014772 \quad (4)$$



$$IG(\text{Age}) = 1 - \left[\frac{3}{11} I(0,1) + \frac{7}{11} I(3/7, 4/7) + \frac{4}{11} I(1,0) \right] = 1 - \left[\frac{3}{11} (0) + \frac{7}{11} (0,985228) + \frac{4}{11} (0) \right] = 0,507386$$

$$I(0,1) = -0 \log(0) - 1 \log(1) = 0$$

$$I(1,0) = -1 \log(1) - 0 \log(0) = 0$$

$$IG(\text{Age}) = 0,507386 \quad (1)$$



$$IG(\text{Etat civil}) = 1 - \left[\frac{8}{11} I(3/8, 5/8) + \frac{4}{11} I(4/6, 2/6) \right] = 1 - \left[\frac{8}{11} (0,954434) + \frac{4}{11} (0,918296) \right] = 0,0610537$$

$$I(3/8, 5/8) = -\frac{3}{8} \log \frac{3}{8} - \frac{5}{8} \log \frac{5}{8} \approx 0,954434$$

$$I(4/6, 2/6) = -\frac{4}{6} \log \frac{4}{6} - \frac{2}{6} \log \frac{2}{6} \approx 0,918296$$

$$IG(\text{Etat civil}) = 0,0610537 \quad (3)$$



$$IG(\text{Relevé}) = 1 - \left[\frac{4}{11} I(1/4, 3/4) + \frac{7}{11} I(2/6, 4/6) + \frac{4}{11} I(1,0) \right] = 1 - \left[\frac{4}{11} (0,811278) + \frac{7}{11} (0,918296) + \frac{4}{11} (0) \right]$$


$$I(1/4, 3/4) = -\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} \approx 0,811278$$

$$I(2/6, 4/6) = -\frac{2}{6} \log \frac{2}{6} - \frac{4}{6} \log \frac{4}{6} \approx 0,918296$$

$$IG(\text{Relevé}) = 0,309058 \quad (2)$$

b) l'attribut à la racine sera donc l'Age

Oui NON



c) On recalcule le gain d'information

$$IG(\text{Sexe}) = 1 - \left[\frac{4}{7} I(1/4, 3/4) + \frac{3}{7} I(2/3, 1/3) \right] = 1 - \left[\frac{4}{7} (0,811278) + \frac{3}{7} (0,918296) \right] \approx 0,142857$$



$$IG(\text{Etat civil}) = 1 - \left[\frac{4}{7} I(2/4, 2/4) + \frac{3}{7} I(1/3, 2/3) \right] = 1 - \left[\frac{4}{7} (1) + \frac{3}{7} (0,918296) \right] = 0,035016$$



$$IG(\text{Relevé}) = 1 - \left[\frac{2}{7} I(0,1) + \frac{3}{7} I(1/3, 2/3) + \frac{2}{7} I(1,0) \right] = 1 - \left[0 + \frac{3}{7} (0,918296) + 0 \right] = 0,606445$$

d) Recalculé le gain pour état civil et sexe



$$IG(\text{Sexe}) = 1 - \left[\frac{2}{3} I(0,1) + \frac{1}{3} I(1,0) \right] = 1$$



$$IG(\text{Etat civil}) = 1 - \left[\frac{2}{3} I(1/2, 1/2) + \frac{1}{3} I(0,1) \right] = 1 - \frac{2}{3} \cdot 1 = 0,333$$

Il est clair qu'il faut choisir l'attribut Sexe, car les sous-ensembles sont plus constants (séparation claire de Oui et Non), il y a moins de mélange que dans le cas de l'état civil. Donc, le gain d'information est en conséquence plus grand. Ensuite état civil n'apportera pas plus d'informations, alors on peut conclure l'arbre ici.

2) Achat ou pas achat

<F, 18-35, célibataire, Moyen>

* En parcourant l'arbre branche par branche selon les caractéristiques de la cliente, la prédiction d'achat est « Oui ». Donc la cliente achèterait le produit.

On ne remarque pas nécessairement de problèmes dans l'arbre, mais une bonne piste d'amélioration serait qu'il serait pertinent d'obtenir d'autres données plus précises ou une plus grande taille d'échantillon, car on a vu qu'"Etat civil" n'apporte quasiment pas de gain dans cet échantillon, alors que si on avait des données plus précises on pourrait améliorer la précision ou

Naïve Bayes

1) Probabilités à calculer

Modèle $P(C|X)$

où $C = \{\text{Oui}, \text{Non}\} \in \text{Achat}$ $X_1 \dots X_4$ où

$X_1 = \text{Sexe}$

$X_4 = \text{Revenu}$

$X_2 = \text{Âge}$

$X_3 = \text{État civil}$

1.1) la probabilité à priori : $P(C = \text{achat})$

car on veut déterminer la probabilité d'avoir un achat ou pas pour un objectif de ventes.

1.2) les probabilités conditionnelles

- $P(X_1 = \text{Sexe} | c)$
- $P(X_2 = \text{Âge} | c)$
- $P(X_3 = \text{État civil} | c)$
- $P(X_4 = \text{Revenu} | c)$

* dans le problème avec le cas de la cliente ce serait:

- $P(\text{Sexe} = F | c)$
- $P(\text{Âge} = 18-35 | c)$
- $P(\text{Éc} = \text{célib} | c)$
- $P(\text{Revenu} = \text{Moyen} | c)$

$P(F, 18-35, \text{célibataire}, \text{Moyen} | c = \text{Oui})$

$P(F, 18-35, \text{célibataire}, \text{Moyen} | c = \text{Non})$

2) Calculez les probabilités

a) Priori • $P(\text{Achat} = \text{oui}) = \frac{7}{14} = \frac{1}{2} = 0,5$

8 fois

• $P(\text{Achat} = \text{Non}) = \frac{7}{14} = \frac{1}{2} = 0,5$

conditionnelle :

* Pour achat = Oui

- $P(\text{Sexe} = F | c = \text{oui}) = 4/7$
- $P(\text{Sexe} = M | c = \text{oui}) = 3/7$

- $P(\text{Âge} = <18 | c = \text{oui}) = 0$
- $P(\text{Âge} = 18-35 | c = \text{oui}) = 3/7$
- $P(\text{Âge} = >35 | c = \text{oui}) = 4/7$

- $P(\text{Éc} = \text{Marié} | c = \text{oui}) = 4/7$
- $P(\text{Éc} = \text{célib} | c = \text{oui}) = 3/7$

- $P(\text{Rev} = \text{faible} | c = \text{oui}) = 1/7$
- $P(\text{Rev} = \text{Moyen} | c = \text{oui}) = 2/7$
- $P(\text{Rev} = \text{élevé} | c = \text{oui}) = 4/7$

* Pour achat = Non

- $P(\text{Sexe} = F | c = \text{non}) = 4/7$
- $P(\text{Sexe} = M | c = \text{non}) = 3/7$

- $P(\text{Âge} = <18 | c = \text{non}) = 3/7$
- $P(\text{Âge} = 18-35 | c = \text{non}) = 4/7$
- $P(\text{Âge} = >35 | c = \text{non}) = 0$

- $P(\text{Éc} = \text{Marié} | c = \text{non}) = 2/7$
- $P(\text{Éc} = \text{célib} | c = \text{non}) = 5/7$

- $P(\text{Rev} = \text{faible} | c = \text{non}) = 3/7$
- $P(\text{Rev} = \text{Moyen} | c = \text{non}) = 4/7$
- $P(\text{Rev} = \text{élevé} | c = \text{non}) = 0$

3) Probabilité d'achat

Oui

$$P(F, 18-35, \text{Célib}, \text{Moyen} | \text{Achat} = \text{oui}) = 4/7 \cdot 3/7 \cdot 3/7 \cdot 2/7 = 0,0299875$$

Non

$$P(F, 18-35, \text{Célib}, \text{Moyen} | \text{Achat} = \text{Non}) = 4/7 \cdot 4/7 \cdot 5/7 \cdot 4/7 = 0,133278$$

$$P(\text{cliente} | \text{oui}) = \frac{0,0299875}{0,0299875 + 0,133278} = 0,183673 \approx 18\%$$

$$P(\text{cliente} | \text{Non}) = \frac{0,133278}{0,0299875 + 0,133278} = 0,816327 \approx 82\%$$

Conclusion: la probabilité d'acheter est de 18% et la probabilité de ne pas acheter est de 82%.

la probabilité à posteriori est plus élevée pour Achat = non dans le cas du problème. On arrive à une réponse différente de l'arbre de décision. Alors la prédiction est qu'il n'y aura pas d'achat.